

AgentCorp

找到那个 真正合得来的 Agent

把「这个 Agent 适不适合我的活」，
从凭感觉，变成有依据。

面向企业与个人的 Agent 适配与协同平台

MIT 开源 | 团队：【请填写】



一页纸速览

为谁做、解决什么、怎么解、凭什么可信。

■ 项目名称

AgentCorp：Agent 适配与协同平台

■ 问题与场景

Agent 数量爆发，但选型全凭感觉。跑分测的是模型通用能力，不是「它能不能融进我这条工作流」。

■ 核心解决方案

用真实工种任务做多维实测，算出「它与你的契合度」；再把合适的几个 Agent 组成团队，嵌进你原有的工作流。

■ 创新点与差异化

① 以真实任务与真实工作流为评估基准，不做通用跑分 ② 评估视角参数化：同一 Agent 对不同的人给出不同契合度

■ 开放 / 复用价值

MIT 开源。评估方法层、能力注册内核、观测投影三者可被任何做 Agent 评估的团队单独取用。

■ 当前进展

四个职能 Agent 与五个能力单元可运行，闭环可离线跑通并留存证据；651 + 282 项自动化测试通过。

01

Agent 变多了，选择反而更难

从「有没有 Agent 可用」，到「哪个 Agent 真的帮得上我」。

每天都有新 Agent，可我该用哪一个

开源仓库、模型广场、各家产品——候选越来越多，可判断依据几乎没有变。

■ 能看到的信息

star 数、README 写得好不好

别人一句「挺好用」


一张跑分榜上的名次

■ 真正想知道的

它能不能接住我这类活

多轮沟通下来顺不顺手

放进我现有流程里会不会卡住



两者之间，隔着一整条鸿沟。

跑分很高，不代表能替你干这份活

标准化题库测的是模型的通用能力；而你的活有上下文、有约束、要交付。

■ 榜单里的题


题面清晰、答案唯一

单轮问答，无历史、无偏好

■ 你手上的活

需求先是模糊的，边聊边清楚

有你的口味、习惯与既定流程



同一个模型，在离线评测里和在你的对话里，
行为并不一致。

Wang, Ho & Koyejo, Patterns 2025

真实的活，是这样发生的

所以评估必须发生在同样的语境里，而不是一道标准题上。

■ ① 需求一开始是模糊的


「帮我把这个整理一下」

■ ② 靠多轮对话逐步澄清

追问、举例、修正，才对齐

■ ③ 人始终在回路里

关键处由人拍板，不是全自动



评估要测的，正是这三件事做得好不好。

02

所以我们换一种测法

不比通用能力，比「和你的活合不合得来」。

我们测的是契合度，不是分数

同一个 Agent，对不同的人、不同的活，会得到不同的契合度。

■ 一个总分说明不了什么


有人最看重不返工，有人最看重快
压成一个数，取舍信息就没了

■ 所以我们做两件事

按六个通用维度 + 工种专项维度分别打分

把「你是谁、你在意什么」作为参数传入

客观榜与主观榜并列，不合成唯一名次
 $\text{契合度} = \text{你的权重} \times \text{它的表现}$



题目来自真实工种，不是学术数据集

所有候选做同一套题、按同一份标准判定，新发布的 Agent 也能被公平看见。

■ 写代码

合并脏数据并给测试用例
定位并发计数错误
给公开接口做安全加固

■ 写文案

同一内容改写给不同读者
事实性校核与来源标注
压缩到指定字数不失信息

■ 做图

从需求描述推出画面参数
系列图的一致性维持
冲突约束下的取舍

两道设计，让分数经得起看

■ 逐条判定，必须引用原文


裁判要对每条要点标注命中与否
找不到原文支撑的，一律记未命中

■ 题面内置反注水探针

「已充分测试」却给不出用例，会被识别
空话说得越漂亮，暴露得越明显

一个 Agent 往往不够，需要一支队伍

把合适的几个 Agent 按职能组队，嵌进你已有的流程，而不是让你迁就它们。



■ 按职能组队

谁负责拆解、谁执行、谁复核

分工与权限写进角色定义

■ 嵌进原有 workflow

不同环节交给不同 Agent

空缺的环节仍由人来补位

03

让这支队伍真的能干活

分工、交接、留痕，以及人在关键处说了算。

四个职能，各自的边界写在代码里

谁能做什么、不能做什么、哪些动作必须人点头，都是程序读取的字段。

■ 决策

提出需求、设定偏好
对上线与撤回拍板

唯一放行权

■ 编排

拆解任务与分发
传递上下文、追踪状态

不可绕过决策方

■ 出题

把岗位要求拆成考察点
多轮提问与追问

不参与打分

■ 评分

多维度实测评分
重复测量与稳定性检查

不参与放行

交接环节	传递什么	为什么这样设计
决策 → 出题	岗位要求与偏好	出题必须对准真实需求
出题 → 评分	实测记录与考察点	只依据实际作答，不看来源
评分 → 决策	分数、稳定性、原文证据	决策者拿到的是证据，不是结论

人不在流程之外，而在回路之上

高风险动作在人点头之前，真的执行不了——不是一句提示语。

■ 拦得住

判定为高风险，动作不执行

流程挂起，等人决定


人点放行，动作才真正发生

■ 撤得回

已执行的动作按相反顺序撤销

某一条撤不掉会明确报出来

不假装「已完全回滚」



实测：判定「录用」后，台账里是 0 条记录——它没敢自己录用。

04

凭什么相信这个结论

先解决一个前提：让模型当裁判，裁判自己靠不靠谱。

同一份答案连打三次，分数常常不一样

所以我们不采信单次打分，而是用一整套办法压住噪声。

■ 重复测量，取严不取宽

同一份答案独立评多次

每一次都达标才算达标

有一次掉下来，就不算可靠

■ 打飘了要能被发现

检查多次评分之间的离散程度

波动过大就下调置信度并转人工

同时检查评分的一致性水平

■ 抵抗常见偏见

每轮打乱维度顺序，避免顺序影响

明确要求不因回答长就给高分

评分锚点固定，减少主观漂移

■ 分数来源必须标清楚

真实裁判 / 部分降级 / 完全降级

降级产生的结论不进经验库

宁可标未评，也不填一个数

我们只主张结论稳定，不主张结论正确——后者需要长期数据验证。

每一步都留得下、看得懂、追得回

执行轨迹按行业通用字段记录，可回放、可归因、可接入通用观测平台。

■ 记什么

哪个 Agent、调用了哪个能力

耗时、token 用量与成本


每一步的输入、输出与状态

■ 为什么这样记

用通用语义字段，不锁定观测平台

整条链路可原样回放复核

审批与撤回同样进流水



05

现在到哪了，以及往哪走

能跑、能验、能复现；也说清楚还没做到什么。

不是一张概念图，是能跑起来的东西

所有数字都可以用公开命令复现，验证报告由脚本生成。

651

前端自动化测试通过

282

服务端测试通过

12 × 3

真实工种题 × 工种

0

类型与规范检查错误

■ 已经能做的

四职能协同的完整闭环可离线跑通

真实工种实测题与多维评分

人工审批与撤回、全链路留痕

可挂接外部标准工具服务

■ 正在做的

把评估层与执行层端到端打通

接入通用观测后端

扩充工种题库与真实任务样本

对外发布可复用的能力接口

我们还没做到什么

一个说不清自己边界的评估系统，本身就不值得信任。

边界	实际情况
稳 ≠ 准	目前验证的是结论稳定，尚未验证它能预测真实表现
重复测量的含义	现在测的是裁判稳不稳，还不是 Agent 干活稳不稳
样本规模	题库覆盖三类工种，尚未覆盖更多行业与长流程任务
观测	通用字段已对齐，尚未接入观测后端
适用范围	只用一次、只有一个候选时，这套流程是额外开销

■ 下一步最重要的一件事

把「准入时的契合度评分」与「上线后的真实表现」做相关性验证。

相关，就固化权重；不相关，就公开这个结果并重做维度体系。

开源的不是一个演示，是三个能单独取用的部件

任何做 Agent 评估的团队，都可以只拿走其中一个。

■ 评估方法层

重复测量与稳定性检查

评分偏差与一致性审计

抗偏见的评分提示词

适用于任何模型当裁判的场景

■ 能力注册内核

可注册、可覆盖、可注销

同类能力可替换实现

与具体框架解耦

可移植到其他 Agent 框架

■ 观测投影

自有轨迹 → 行业标准字段

纯函数、零依赖

可接任意兼容的观测后端

不锁定观测供应商

开放项	内容
开源协议	MIT
接口契约	工具调用的参数结构、鉴权、错误约定与审计要求
第三方依赖	前端 React 生态、桌面端 Electron、服务端 FastAPI，均为开源协议

团队介绍

请按官方要求填写：成员背景、分工、过往成果。

■ 【成员一 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

■ 【成员二 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

■ 【成员三 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

项目	内容
团队成果	【过往项目经历 / 获奖经历】
作品合集	【作品集或个人主页链接】
代码仓库	【仓库地址】（MIT 开源）

Agent 会越来越多。
难的从来不是找到一个能用的，
而是找到那个真正合得来的。

附录：评分维度对照

本页供评审按维度检索对应内容；现场讲述可跳过。

评分维度	权重	对应页
场景价值与行业可复制性	25%	第 03 – 05 页：选择困难 → 跑分失配 → 真实工作的样子
多 Agent 协同与自主闭环能力	25%	第 09 – 10 页：四职能分工与交接、人在回路与撤回
Skill 工程体系与生态复用	25%	第 07 页：真实工种题与判定设计；第 15 页：可复用部件
工程落地与安全可审计	20%	第 11 – 13 页：裁判可靠性、全链路留痕、可复现证据
开放 / 开源贡献	5%	第 15 页：三个可单独取用的部件与接口契约