


AgentCorp

为你的工作流， 招一支合得来的团队

不选最强的 Agent，选最合得来的那一个。

面向企业与个人的 Agent 适配与协同平台 · 数字人事部
MIT 开源 | 团队：【请填写】



一页纸速览

为谁做、解决什么、怎么解、凭什么可信。

■ 项目名称

AgentCorp：Agent 适配与协同平台

■ 核心解决方案

用真实工种任务做多维实测，算出「它与你」的契合度；再把合适的几个 Agent 编成一支队伍，嵌进你原有的流程。

■ 开放 / 复用价值

MIT 开源。评估方法层、能力注册内核、观测投影三者互不依赖，任何做 Agent 评估的团队都可以只取走其中一个。

■ 问题与场景

Agent 的供给在爆发，选型的依据却没有跟上。跑分衡量的是模型的通用能力，回答不了「它能不能融进我这条工作流」。

■ 创新点与差异化

其一，评估发生在真实工作流里——模糊需求、多轮澄清、人在回路，而不是一道标准题；其二，评估视角是参数，同一个 Agent 对不同的人给出不同的契合度。

■ 当前进展

四个职能 Agent 与五个能力单元可运行，闭环能离线跑通并留存证据，651 + 282 项自动化测试通过。


01

供给在增长，契合才是解药

问题已经不是「有没有 Agent 可用」，而是「哪一个真的接得住我的活」。

一个职场人的一天，从来不是一道题

需求半路才说清、上下文散在几个窗口里、真正的决定还得自己拍板。



■ 上午

一句「帮我把这个整理一下」开始，边做边问才知道到底要什么。

■ 下午

同一件事在三个工具之间来回搬运，上下文靠人脑接力。

■ 下班前

真正有风险的那一步，仍然要自己确认了才敢发出去。

一天里真正耗人的，不是难题，而是拼接——把工具、上下文和判断一次次接起来。

Agent 供给在增长，契合才是选择困难症的解药

候选每周都在变多，可用来判断的依据，还停留在几年前。


■ 我们能看到的

star 数、一份写得漂亮的 README、别人一句「挺好用」，以及某张榜单上的名次。

■ 我们真正想问的

它接不接得住我这类活？多轮沟通下来顺不顺手？放进我现有的流程里，会不会卡住？

看得到的都是别人的经验，想问的全都关于自己。



跑分很高，不等于能替你干这份活


榜单衡量的是模型有多强，而你要判断的是它与你这条流程合不合得上。

■ 榜单里的题

题面清晰、答案唯一、一问一答，没有历史，也没有你的偏好。

■ 你手上的活

需求先是模糊的，边聊边清楚；还带着你的口味、习惯和既定流程。



强弱是模型的属性，合不合适是你和它之间的关系。

同一个模型，在离线评测里与在真人对话里，行为并不一致。

Wang, Ho & Koyejo, Patterns 2025

真实的职场，和干净的跑分榜，隔着一整个现场


所以评估必须回到同样的语境里发生，而不是一间没有噪声的实验室里完成。

■ 实验室里的评测

条件干净、任务封闭、一次成型：题目给定，答案可对照，过程不必留痕。

■ 现场发生的工作

需求模糊、要多轮澄清、人始终在回路里：关键处由人拍板，而不是全自动跑完。



我们要测的，正是它在这种「不干净」里的表现。

02

所以我们换一种测法

不比通用能力的高下，只比它和你的活合不合得来。

我们给出的不是分数，是契合度

契合度 = 你在意什么 × 它在这些方面的实测表现，因人而异，也因活而异。


■ 一个总分说明不了什么

有人最怕返工，有人最要速度。压成一个数，取舍的信息就没了。

■ 所以我们把视角变成参数

六个通用维度加工种专项维度分别成绩，再按你的权重加权；客观榜与主观榜并列呈现，不合成唯一名次。

同一个 Agent，换个人看，排名就不同



契合度不是它有多好，而是它与你有多合。

题目取自真实工种，判定不靠印象

所有候选做同一套题、按同一份标准判定，新发布的 Agent 也能被公平地看见。

■ 写代码

合并脏数据并补测试、定位并发计数错误、给公开接口做安全加固。

■ 写文案

同一内容改写给不同读者、事实校核并标注来源、压缩字数而不丢信息。

■ 做图

从一段需求描述推出画面参数、维持系列图的一致性、在冲突约束下取舍。

两道设计，让分数经得起追问

■ 逐条判定，且必须引用原文

裁判要为每一条要点标注命中与否，找不到原文支撑的一律记未命中。

■ 题面内置反注水探针

声称「已充分测试」却给不出用例，会被当场识别——空话说得越漂亮，暴露得越明显。

我们不追求测得多，只追求每一分都能指回一段原文。

一个 Agent 往往不够，要的是一次排兵布阵

按职能挑人、按流程落位——让队伍嵌进你已有的工作方式，而不是让你迁就它们。


■ 先看阵型，再看单点

组队看的不是每个位置上最强的那个，而是这几个凑在一起，能不能把这条流程从头跑到尾。

■ 落位到你现有的流程

哪个环节交给谁、交接时带什么上下文、哪些环节仍然由人补位，都在组队时一并定下来。

选人只是第一步，摆得对位置，队伍才成立。



03

让这支队伍真的能干活

分工、交接、留痕，以及在关键处始终由人说了算。

四个职能，边界写在代码里而不是写在文档里

谁能做什么、不能做什么、哪些动作必须人点头，都是程序会读取的字段。

■ 决策

提出需求、设定偏好，并对上线与撤回拍板。

唯一放行权

■ 编排

拆解任务、分发执行，沿途传递上下文与状态。

不可绕过决策方

■ 出题

把岗位要求拆成考察点，多轮提问并追问。

不参与打分

■ 评分

多维度实测评分，并做重复测量与稳定性检查。

不参与放行

交接时传递什么，决定了这条链路可不可信

交接环节	传递什么	为什么这样设计
决策 → 出题	岗位要求与偏好	题目必须对准真实需求，而不是通用题库
出题 → 评分	实测记录与考察点	只依据实际作答判定，不看候选来自哪里
评分 → 决策	分数、稳定性与原文证据	决策者拿到的是证据，不是一句结论

人不在流程之外，而在回路之上


高风险动作在人点头之前真的执行不了——这是一道门，不是一句提示语。

■ 拦得住

一旦判定为高风险，动作不会执行，流程原地挂起等人决定；人点了放行，它才真正发生。

■ 撤得回

已执行的动作按相反顺序撤销；哪一条撤不掉会被明确报出来，不假装「已完全回滚」。



实测：判定「录用」之后，台账里是 0 条记录——它没有自己动手。

04

凭什么相信这个结论

先解决一个前提：让模型当裁判，裁判自己靠不靠谱。

同一份答案连打三次，分数常常并不一样

所以我们不采信任何一次单独的打分，而是用一整套办法把噪声压下去。

■ 重复测量，取严不取宽

同一份答案独立评多次，每一次都达标才算达标；有一次掉下来，就不算可靠。

■ 打飘了要能被发现

检查多次评分之间的离散程度，波动过大就下调置信度并转人工复核。

■ 抵抗已知的偏见

每轮打乱维度顺序以避开位置效应，并明确要求不因回答长就给高分。

■ 分数的来源必须标清楚

真实裁判、部分降级还是完全降级，逐条标注；降级产生的结论不进经验库。

我们只主张结论稳定，不主张结论正确——后者需要长期的真实数据来验证。

每一步都留得下、看得懂、追得回


执行轨迹按行业通用字段记录，可回放、可归因，也可接入通用观测平台。

■ 记什么

哪个 Agent 调用了哪个能力、耗时与成本多少、每一步的输入输出与状态，全部逐条落盘。

■ 为什么这样记

字段采用通用语义，不绑定任何一家观测平台；整条链路可原样回放，审批与撤回也一并进流水。



可追溯不是附加功能，它是「可信」这两个字的前提。

现在到哪了，以及往哪走

能跑、能验、能复现；也把还没做到的部分一并说清楚。

不是一张概念图，是能跑起来的东西

下列数字都可以用公开命令复现，验证报告由脚本生成而非手写。

651

前端自动化测试通过

282

服务端测试通过

12 × 3

真实工种题 × 工种

0

类型与规范检查错误

■ 已经能做的

四个职能协同的完整闭环可离线跑通，包含真实工种实测、多维评分、人工审批与撤回，以及全链路留痕；也能挂接外部标准工具服务。

■ 正在做的

把评估层与执行层端到端打通、接入通用观测后端、扩充工种题库与真实任务样本，并对外发布可复用的能力接口。

我们还没做到什么

一个说不清自己边界的评估系统，本身就不值得被信任。

边界	实际情况
稳 ≠ 准	目前验证的是结论稳定，尚未验证它能预测真实表现
重复测量的含义	现在测的是裁判稳不稳，还不是 Agent 干活稳不稳
样本规模	题库覆盖三类工种，尚未覆盖更多行业与长流程任务
观测	通用字段已对齐，尚未接入观测后端
适用范围	只用一次、只有一个候选时，这套流程属于额外开销

■ 下一步最重要的一件事

把「准入时的契合度评分」与「上线后的真实表现」做相关性验证：相关，就固化这套权重；不相关，就公开这个结果并重做维度体系。

开源的不是一个演示，是三个能单独取用的部件

任何在做 Agent 评估的团队，都可以只拿走其中一个，而不必接受整套框架。

■ 评估方法层

重复测量与稳定性检查、评分偏差与一致性
审计、抗偏见的评分提示词。

适用于任何以模型当裁判的场景

■ 能力注册内核

可注册、可覆盖、可注销，同类能力允许替
换实现，与具体框架解耦。

可移植到其他 Agent 框架

■ 观测投影

把自有轨迹映射为行业标准字段，纯函数、
零依赖。

不锁定任何观测供应商

开放项	内容
开源协议	MIT
接口契约	工具调用的参数结构、鉴权方式、错误约定与审计要求
第三方依赖	前端 React 生态、桌面端 Electron、服务端 FastAPI，均为开源协议

团队介绍

请按官方要求填写：成员背景、团队分工与过往成果。

■ 【成员一 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

■ 【成员二 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

■ 【成员三 · 角色】

学校 / 公司：【填写】

岗位 / 专业：【填写】

核心技能：【填写】

本项目分工：【填写】

项目	内容
团队成果	【过往项目经历 / 获奖经历】
作品集	【作品集或个人主页链接】
代码仓库	【仓库地址】（MIT 开源）

Agent 只会越来越多。
难的从来不是找到一个能用的，
而是找到那个合得来的。

附录：评分维度对照

本页供评审按维度检索对应内容；现场讲述可跳过。

评分维度	权重	对应页
场景价值与行业可复制性	25%	第 03 – 06 页：一天的现场 → 选择困难 → 跑分失配 → 现场与榜单的差距
多 Agent 协同与自主闭环能力	25%	第 10 – 11 页：四职能分工与交接、人在回路与撤回
Skill 工程体系与生态复用	25%	第 08 页：真实工种题与判定设计；第 16 页：可复用部件
工程落地与安全可审计	20%	第 12 – 14 页：裁判可靠性、全链路留痕、可复现证据
开放 / 开源贡献	5%	第 16 页：三个可单独取用的部件与接口契约