


AgentCorp

为你的 workflow, 招一支合得来的团队

不选最强的 Agent, 选最合得来的那一个。

面向企业与个人的 Agent 适配与协同平台 · 数字人事部
MIT 开源 |



一页纸速览

为谁做、解决什么、怎么解、凭什么可信。

■ 项目名称

AgentCorp：Agent 适配与协同平台

■ 核心解决方案

用真实工种任务做多维实测，算出「它与你」的契合度；再把合适的几个 Agent 编成一支队伍，嵌进你原有的流程。

■ 开放 / 复用价值

MIT 开源。评估方法层、能力注册内核、观测投影三者互不依赖，任何做 Agent 评估的团队都可以只取走其中一个。

■ 问题与场景

Agent 的供给在爆发，选型的依据却没有跟上。跑分衡量的是模型的通用能力，回答不了「它能不能融进我这条工作流」。

■ 创新点与差异化

其一，评估发生在真实工作流里——模糊需求、多轮澄清、人在回路，而不是一道标准题；其二，评估视角是参数，同一个 Agent 对不同的人给出不同的契合度。

■ 当前进展

四个职能 Agent 与五个能力单元可运行，闭环能离线跑通并留存证据，651 + 282 项自动化测试通过。


01

供给在增长，契合才是解药

问题已经不是「有没有Agent可用」，而是「哪个Agent真的接得住我干的活」。

职场人的一天，从来不是一道对错题

需求半路才说清、上下文散在几个窗口里、真正的决定还得自己拍板。



■ 上午

一句「帮我把这个整理一下」开始，边做边问才知道需求和方向到底要怎么走。

■ 下午

同一件事在多个工具之间来回搬运，上下文靠人脑接力。

■ 下班前

真正有风险的决定思考再三，仍然要自己确认了才敢发出去。

一天里真正耗人的，不是难题，而是接力——把思路、工具、上下文和判断力一次次接力起来。

Agent 供给在增长，契合才是选择困难症的解药

候选每周都在变多，可用来判断的依据，还停留在几年前。


■ 小白所能看到的

star 数、一份漂亮的 README、别人一句「挺好用」，以及某张榜单上的名次。

■ 我们真正想问的

它接不接得住我这类活？多轮沟通下来顺不顺手？放进我现有的流程里，会不会卡住？

看得到的都是别人的经验，想问的全都是关于自己



跑分很高，不等于能替你干这份活


榜单衡量的是模型有多强，而你要判断的是它与你这条流程合不合得上。

■ 榜单里的题

题面清晰、答案唯一、一问一答，没有长期使用历史，也没有你的偏好。

■ 你手上的活

需求先是模糊的，边聊边清楚；带着你的口味、审美、习惯和既定流程。



强弱是模型的属性，合不合适是你和它之间的关系

同一个模型，在离线评测里与在真人对话里，行为并不一致

。

真实的职场，和干净的跑分榜，隔着整个现场


所以评估必须回到同样的语境和职场里发生，而不是一间没有噪声的实验室里完成。

■ 实验室里的评测

条件干净、任务封闭、一次成型：题目给定，答案可对照，过程不必留痕。

■ 现场发生的工作

需求模糊、要多轮澄清、人始终在回路里：关键处由人拍板，而不是全自动跑完。



我们要探讨的测评，正是在这种「不干净」里的表现

02

所以我们换一种测法推荐Agent

不只是比通用能力的高下，更比它和你的活合不合得来。

我们给出的不只是分数，更是契合度

契合度 = 你在意什么 × 它在这些方面的实测表现，因人而异，也因活而异。


■ 一个总分说明不了什么

有人最怕返工，有人最要速度。压成一个平均值，让人取舍的信息就丢失了

■ 所以我们把视角变成参数

六个通用能力维度 + 工种专项维度分别成绩，再按用户的权重加权；模型打分的客观榜与用户的主观榜并列呈现，不合成单一的榜单推荐。

同一个 Agent，换个人看，排名就不同



契合度不是它有多好多强，而是它与你有多合拍。

题目灵感取自HR面试场景，LLM判定不只靠印象分

所有候选做同一套题、按同一份标准判定，新发布的 Agent 也能被公平地看见。

■ 写代码

合并脏数据并补测试、定位并发计数错误、给公开接口做安全加固。

■ 写文案

同一内容改写给不同读者、事实校核并标注来源、压缩字数而不丢信息。

■ 做图

从一段需求描述推出画面参数、维持系列图的一致性、在冲突约束下取舍。

两道设计，让分数经得起追问

■ 逐条判定，且必须引用原文

裁判要为每一条要点标注命中与否，找不到原文支撑的一律记未命中。

■ 题面内置反注水探针

声称「已充分测试」却给不出用例，会被当场识别——Agent空话说得越漂亮，暴露得越明显。Agent, Show me your code。

我们目前不追求benchmark的题目测得多，更追求每次打分都有迹可循。

Agent不能单打独斗，复杂任务需要排兵布阵


按职能挑人、按流程落位——让数字员工嵌进你已有的工作方式，而不是让你迁就它们。

■ 先看阵型，再看单点

组队看的不是每个位置上最强的那个，而是这几个凑在一起，能不能把这条流程从头跑到尾。

■ 落位到你现有的流程

哪个环节交给谁、交接时带什么上下文、哪些环节仍然由人补位，都在组队时一并定下来。



选人只是第一步，摆得对位置，队伍才成立。让用户体会到带领数字员工攻坚克难的良好感觉。

03

让这支队伍真的能干活

分工、交接、留痕，以及在关键处始终由人说了算。

AgentCorp的四个Agent通力合作

谁能做什么、不能做什么、哪些动作必须人点头，都是程序会读取的字段。

■ 决策Agent

辅佐用户提出需求、设定偏好，并对上线与撤回拍板。

唯一放行权

■ 编排Agent

拆解任务、分发执行，沿途传递上下文与状态。

不可绕过决策方

■ 出题Agent(HR)

把岗位要求拆成考察点，多轮提问、追问、评估印象分

不参与绩效打分

■ 绩效Agent(赛博人事)

多维度实测评分(Agent的KPI)，长期测量与稳定性

不参与放行

交接时传递什么，决定了这条链路可不可信

交接环节	传递什么	为什么这样设计
决策 → 出题	岗位要求与偏好	题目必须对准用户的真实工作需求，而不是通用题库
出题 → 评分	实测记录与考察点	只依据实际作答判定，不看候选Agent来自哪里
评分 → 决策	分数、稳定性与原文证据	决策者拿到的是客观证据，不是一句简单的结论

人不在流程之外，而在回路之上


Agent要辅佐人上树摘果子，不能替人摘果后让人守株待兔

■ 拦得住 · 决定权不外包

高风险动作在人点头之前不会执行，流程原地挂起等你决定。
每一次放行都是一次真实的职业判断，判断力用进废退——AgentCorp 把这些关口留在人手里。

■ 撤得回 · 敢于亲自试更难

已执行的动作按相反顺序撤销，撤不掉的会被明确报出来。试错成本可控，人才敢去碰那些更难、更值得练的决策，而不是因为怕出错就绕开。



我们想让人越用越熟练，而不是越用越不敢自己动手

04

凭什么相信这个结论

先解决一个前提：让模型当裁判，裁判自己靠不靠谱。

同一份答案连打三次，分数常常并不一样

所以我们不采信任何一次单独的打分，而是用一整套办法把噪声压下去。

■ 重复测量，取严不取宽

同一份答案独立评多次，每一次都达标才算达标；有一次掉下来，就不算可靠。

■ 打飘了要能被发现

检查多次评分之间的离散程度，波动过大就下调置信度并转人工复核。

■ 抵抗已知的偏见

每轮打乱维度顺序以避开位置效应，并明确要求不因回答长就给高分。

■ 分数的来源必须标清楚

真实裁判、部分降级还是完全降级，逐条标注；降级产生的结论不进经验库。

我们只主张结论稳定，目前不主张结论正确——后者需要长期的用户真实数据来验证，描绘更精准的职场画像。

每一步都留得下、看得懂、追得回


执行轨迹按行业通用字段记录，可回放、可归因，也可接入通用观测平台。

■ 记什么

哪个 Agent 调用了哪个能力、耗时与成本多少、每一步的输入输出与状态，全部逐条落盘。

■ 为什么这样记

字段采用通用语义，不绑定任何一家观测平台；整条链路可原样回放，审批与撤回也一并进流水。



可追溯不是附加功能，它是「可信」这两个字的前提。

05

现在走到哪里，路在何方

能跑、能验、能复现；也把还没做到的部分一并说清楚。

不是一张概念图，是能跑起来的东西

下列数字都可以用公开命令复现，验证报告由脚本生成而非手写。

651

前端自动化测试通过

282

服务端测试通过

12 × 3

真实工种题 × 工种

0

类型与规范检查错误

■ 已经能做的

四个职能协同的完整闭环可离线跑通，包含真实工种实测、多维评分、人工审批与撤回，以及全链路留痕；也能挂接外部标准工具服务。

■ 正在做的

把评估层与执行层端到端打通、接入通用观测后端、扩充工种题库与真实任务样本，并对外发布可复用的能力接口。

我们还没做到什么

复赛及以后的路线图

边界	实际情况
稳 ≠ 准	目前验证的是结论稳定，尚未验证它能预测真实表现
重复测量的含义	现在测的是裁判稳不稳，还不是 Agent 干活稳不稳
样本规模	题库覆盖三类工种，尚未覆盖更多行业与长流程任务
观测	通用字段已对齐，尚未接入观测后端
适用范围	只用一次、只有一个候选时，这套流程属于额外开销

■ 下一步最重要的一件事

把「准入时的契合度评分」与「上线后的真实表现」做相关性验证：相关，就固化这套权重；不相关，就公开这个结果并重做维度体系。

开源的不是一个演示，是三个能单独取用的部件

任何在做 Agent 评估的团队，都可以只拿走其中一个，而不必接受整套框架。

■ 评估方法层

重复测量与稳定性检查、评分偏差与一致性审计、抗偏见的评分提示词。

适用于任何以模型当裁判的场景

■ 能力注册内核

可注册、可覆盖、可注销，同类能力允许替换实现，与具体框架解耦。

可移植到其他 Agent 框架

■ 观测投影

把自有轨迹映射为行业标准字段，纯函数、零依赖。

不锁定任何观测供应商

开放项	内容
开源协议	MIT
接口契约	工具调用的参数结构、鉴权方式、错误约定与审计要求
第三方依赖	前端 React 生态、桌面端 Electron、服务端 FastAPI，均为开源协议

团队介绍

■ 【成员一 · 队长 · 陈思丞】

学校 / 公司：清华大学文化心理学研究中心
岗位 / 专业：心理学专业
核心技能：心理学 + 前端Web、UI设计
本项目分工：AI产品经历

■ 【成员二 · 队员 · 】

学校 / 公司：【填写】
岗位 / 专业：【填写】
核心技能：【填写】
本项目分工：【填写】

■ 【成员三 · 队员 · 】

学校 / 公司：【填写】
岗位 / 专业：【填写】
核心技能：【填写】
本项目分工：【填写】

项目	内容
团队成果	+ Eazo总决赛
作品集	【作品集或个人主页链接】
代码仓库	https://github.com/EriXPsy/AgentCorp.git

未来的Agent 只会越来越多。
难的从来不是找到一个能用的，
而是找到那个合得来的。
